

Universidad Externado de Colombia

Departamento de Matemáticas
Ciencia de Datos

Segunda Entrega Proyecto Integrador

Datos, modelamiento y validación

Proyecto Integrador de Machine Learning I

Autores

Juan Pablo Carrillo Hortua
juan.carrillo6@est.uexternado.edu.co

Diego Alejandro Pineda Abaunza
diego.pineda3@est.uexternado.edu.co

Docente

Julia Carolina Torres Lozano
julia.torres@uexternado.edu.co

Asignatura

Machine Learning I

Bogotá D. C., Colombia
25 de octubre de 2026

Índice

Contenido i

1. Consolidación de los datos 1
- 1.1. Conjunto de datos definitivo . . . 1
- 1.2. Análisis de robustez del método Dual Cutoff . . . 3
- 1.3. Calidad de los datos y análisis exploratorio (EDA) . . . 4

2. Flujo reproducible sin fuga de datos 5
- 2.1. Estructura del pipeline . . . 5
  - 2.1.1. Primera pipeline: aproximación al artículo original . . . 5
  - 2.1.2. Segunda pipeline: Modelo ganador . . . 6
- 2.2. Evaluación mediante validación cruzada . . . 6
- 2.3. Prevención de fuga de información . . . 6

3. Entrenamiento y comparación de modelos 7
- 3.1. Modelo de línea base . . . 7
- 3.2. Modelos evaluados . . . 7
- 3.3. Ajuste y comparación inicial . . . 7
- 3.4. Selección del modelo ganador . . . 8

4. Validación, métricas e interpretación preliminar 10
- 4.1. Estrategia de evaluación . . . 10
- 4.2. Métricas de evaluación . . . 10
- 4.3. Resultados e interpretación . . . 10

Agradecimientos 14

Referencias 15

1. Consolidación de los datos

1.1. Conjunto de datos definitivo

Se utilizaron los microdatos de la Encuesta Nacional de Calidad de Vida (ECV) de 2025 del DANE (Departamento Administrativo Nacional de Estadística (DANE), 2025a). La consolidación de los módulos de personas, hogares y viviendas produjo una base inicial de 235.350 registros de personas y 902 variables, correspondientes a 87.060 hogares y 86.848 viviendas. La construcción de la variable objetivo mediante una adaptación del método de doble corte de Alkire-Foster dio lugar a una base analítica de 44.351 hogares.

Indicadores del IPM adaptado según su rol.

La matriz metodológica se presenta en dos tablas para distinguir los indicadores que participan directamente en el cálculo de la variable objetivo `POBRE` (rol de corte) de los indicadores clasificados como características, que quedan fuera de ese cálculo. Esta separación también permite identificar posibles solapamientos entre las variables que definen la etiqueta y las que podrían considerarse en análisis posteriores.

ECV 2025 · PROYECTO DE MACHINE LEARNING I

IPM adaptado · Indicadores de corte

Indicadores que intervienen directamente en la construcción del puntaje de pobreza (POBRE).

Dimensión	Peso de dimensión	Indicador	Peso en el corte	Variables ECV 2025 que lo construyen	Nota metodológica
Educación	0,20	Logro educativo	0,2000	P6040, P8586, P8587, P8587S1, P6211, P1088, P1088S1, P6216	Único indicador de la dimensión
Niñez y juventud	0,20	Rezago escolar	0,0667	P6040, P8586, P8587, P8587S1, P6211, P1088, P1088S1, P6216	—
Niñez y juventud	0,20	Inasistencia escolar	0,0667	P6040, P8586	—
Niñez y juventud	0,20	Barreras de acceso a cuidado de primera infancia	0,0667	P6040, P6090, P51, P55, P774, P8586, P6180	Usa P6090 para menores de 6 años
Salud	0,20	Barreras de acceso a salud dada una necesidad	0,2000	P5665, P8563	Único indicador de la dimensión
Trabajo	0,20	Desempleo de larga duración	0,2000	P6040, P6240, P6250, P6260, P6270, P6351, P7250, P6920, P8642	Único indicador; hogares sin PEA o solo de pensionados quedan privados
Vivienda y servicios	0,20	Material inadecuado de pisos	0,0667	P4015	—
Vivienda y servicios	0,20	Material inadecuado de paredes exteriores	0,0667	CLASE, P4005	—
Vivienda y servicios	0,20	Hacinamiento crítico	0,0667	CLASE, CANT_PERSONAS_HOGAR, P5010	—

Estos nueve indicadores construyen el puntaje de privación. Los pesos del indicador dentro del corte son los especificados en la matriz metodológica; el umbral empleado en el código es k = 5/15.

ECV 2025 · PROYECTO DE MACHINE LEARNING I

IPM adaptado · Características

Indicadores etiquetados como "Característica" en la matriz: quedan fuera del puntaje de corte.

Dimensión	Peso de dimensión	Indicador	Peso en el corte	Variables ECV 2025 que lo construyen	Nota metodológica
Educación	—	**Analfabetismo**	—	P6160	Revisar R0 frente a logro educativo
Niñez y juventud	—	**Trabajo infantil**	—	P6040, P6240, P6250, P6260, P6270	P6240 a P6270 también definen la PEA del desempleo de larga duración
Salud	—	**Sin aseguramiento en salud**	—	P6040, P6090	Solo personas de 6 años o más; P6090 de menores de 6 años está en el corte
Trabajo	—	**Trabajo informal**	—	P6040, P6240, P6250, P6260, P6270, P6351, P7250, P6920, P8642	Comparte PEA y condición de pensionado con desempleo de larga duración
Vivienda y servicios	—	**Sin acceso a fuente de agua mejorada**	—	CLASE, P8520S5, P8530	Sin variables compartidas con el corte
Vivienda y servicios	—	**Inadecuada eliminación de excretas**	—	CLASE, P8520S3, P8526	Sin variables compartidas con el corte

Estas características no participan directamente en el cálculo del corte. Antes de usarlas como predictores, se deben revisar los solapamientos con variables que sí construyen POBRE para evitar fuga de información.

Nota: Aunque las condiciones de privación son binarias, las características entregadas al modelo conservan su representación original, ya sean proporciones o categorías. La variable objetivo `POBRE`, es binaria (0 = no pobre, 1 = pobre).

El análisis incorpora factores de expansión del DANE para ponderar las medidas de pobreza y las asociaciones. La Figura 1 presenta las correlaciones de Pearson ponderadas para variables numéricas y binarias, así como la V de Cramér ponderada para variables categóricas, en relación con los indicadores que integran el corte de pobreza.

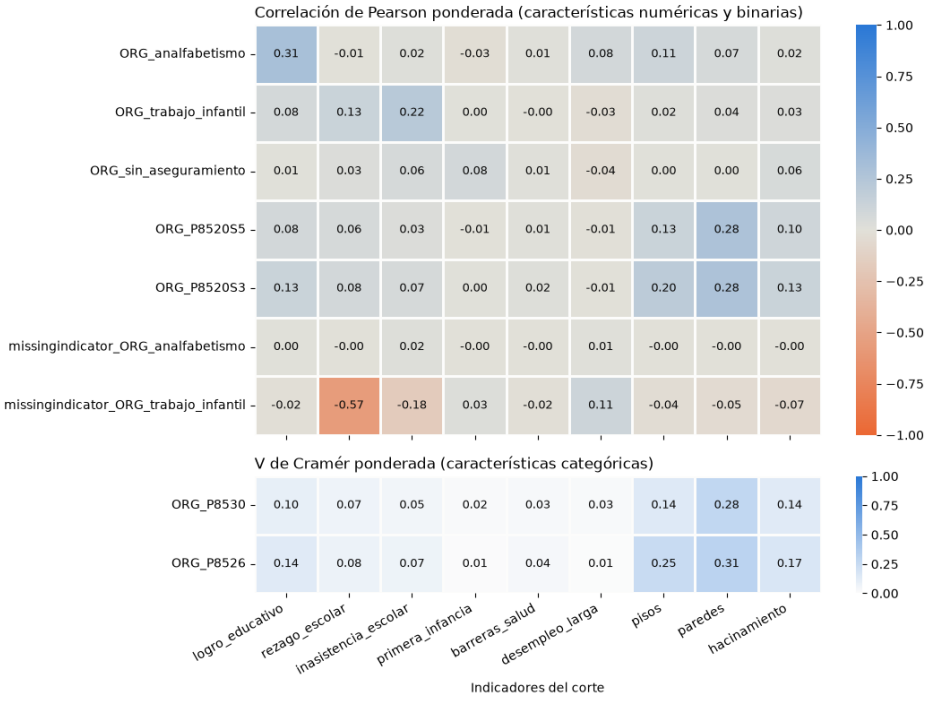


Figura 1. Asociaciones ponderadas entre los predictores candidatos y los indicadores del corte de pobreza.

La asociación más marcada es $r = -0{,}57$ entre el indicador de ausencia de información de trabajo infantil y el rezago escolar. Este resultado debe interpretarse con cautela,

pues puede reflejar diferencias en la composición de los hogares y en la edad de sus integrantes, no necesariamente una relación explicita entre ambas condiciones. Las asociaciones sirven como diagnóstico exploratorio, pero no demuestran por sí solas la existencia o ausencia de fuga de información por causa de caracteristicas redundantes en realacion a los indicadores usados para el corte.

1.2. Análisis de robustez del método Dual Cutoff

Se evaluó la sensibilidad del índice de pobreza multidimensional ante cambios en el umbral k y en la ponderación de las dimensiones. Estos análisis permiten comprobar si las conclusiones sobre la pobreza departamental se mantienen ante distintas decisiones metodológicas.

La Tabla 1 presenta las correlaciones de Kendall entre el ordenamiento departamental del esquema base y escenarios que asignan el 50 % del peso a una dimensión. Valores próximos a uno indican mayor estabilidad del ordenamiento.

Tabla 1. Robustez ante cambios de ponderación

Escenario	Adaptado	DANE
Base	1,000	1,000
50 % educación	0,572	0,811
50 % niñez	0,765	0,773
50 % salud	0,352	0,379
50 % trabajo	-0,159	0,830
50 % vivienda	0,742	0,727

El esquema adaptado muestra mayor sensibilidad al dar el 50 % del peso a trabajo ($\tau = -0,159$) y a salud ($\tau = 0,352$), digase sensible ya que los cambios fueron tantos que los vectores de M_0 de grupos resultantes de los cortes poca relacion tienen con la base. En cambio, el esquema DANE presenta una correlación de 0,830 para trabajo, lo que indica una mayor estabilidad del ordenamiento en ese escenario.

También se examinó la variación del umbral k. La Figura 2 muestra cómo cambia el índice M_0 para distintos departamentos bajo el esquema DANE. Al aumentar k, disminuye M_0, pues se exige un mayor puntaje de privación para clasificar a los hogares como pobres. La línea vertical indica el umbral de referencia $k \approx 0,333$.

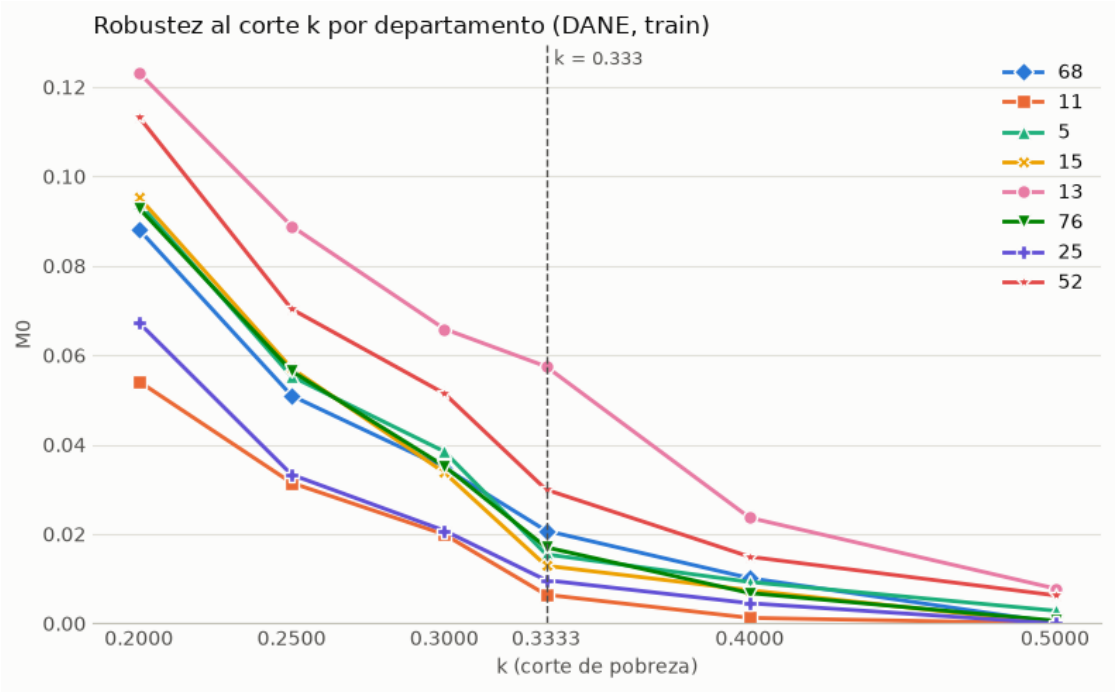


Figura 2. Sensibilidad del índice M_0 ante variaciones del umbral k por departamento, esquema DANE y conjunto de entrenamiento.

En conjunto, el índice M_0 disminuye al aumentar el umbral k, mientras que la jerarquía general de los departamentos representados se mantiene relativamente estable. Aunque se observan algunos cruces entre curvas intermedias, no se aprecia una inversión generalizada del orden. Esto concuerda con el análisis global del esquema DANE, en el que el 77 % de los pares de departamentos conservaron su orden relativo. Por tanto, existe una estabilidad considerable, aunque no absoluta, frente a los cambios del umbral.

1.3. Calidad de los datos y análisis exploratorio (EDA)

Calidad de los datos. La base inicial comprendió 235.350 registros de personas y 902 variables. Tras filtrar las cabeceras municipales y agregar por hogar, se obtuvieron 44.351 hogares, distribuidos en entrenamiento (31.039), validación (6.643) y prueba (6.669). Los valores faltantes se asociaron principalmente con la ausencia de miembros elegibles y se trataron mediante imputación con cero e indicadores de ausencia.

Análisis exploratorio. En el conjunto de entrenamiento, el 12,84 % de los hogares se clasificó como pobre y el 87,16 % como no pobre; la estimación ponderada de pobreza fue del 9 %. El acceso al acueducto (97,39 %) y al alcantarillado (92,35 %) fue elevado, incluso entre hogares pobres.

La prueba de chi-cuadrado encontró asociaciones estadísticamente significativas entre `POBRE` y seis de las siete variables categóricas evaluadas ($p < 0{,}001$). Sin embargo, las V de Cramér (0,047–0,128) indican asociaciones débiles. Para el indicador de ausencia

de `ORG_analfabetismo` no se encontró evidencia de asociación ($p = 0{,}267$); además, el 50 % de las celdas tuvo frecuencias esperadas inferiores a cinco, por lo que no se cumplió el supuesto de frecuencias de la prueba. Los resultados son exploratorios, pues la independencia de las observaciones no pudo verificarse considerando el diseño muestral de la encuesta.

Finalmente, los VIF fueron menores a 5, sin evidencia de multicolinealidad elevada. Se observó una correlación de $r = -0{,}57$ entre trabajo infantil y rezago escolar, posiblemente relacionada con la composición etaria de los hogares.

2. Flujo reproducible sin fuga de datos

2.1. Estructura del pipeline

2.1.1. Primera pipeline: aproximación al artículo original

Esta primera pipeline busca reproducir el enfoque del artículo mediante una regresión logística para predecir la variable objetivo `POBRE`. El flujo incluye la imputación de valores faltantes con cero, la incorporación de indicadores de ausencia y una selección secuencial de seis características mediante el procedimiento *backward*, utilizando *average precision* como criterio de selección.

El modelo utiliza `class_weight='balanced'` para compensar el desbalance entre hogares pobres y no pobres. Esta configuración constituye el punto de partida para examinar alternativas de preprocesamiento y mejorar la identificación de la clase minoritaria.

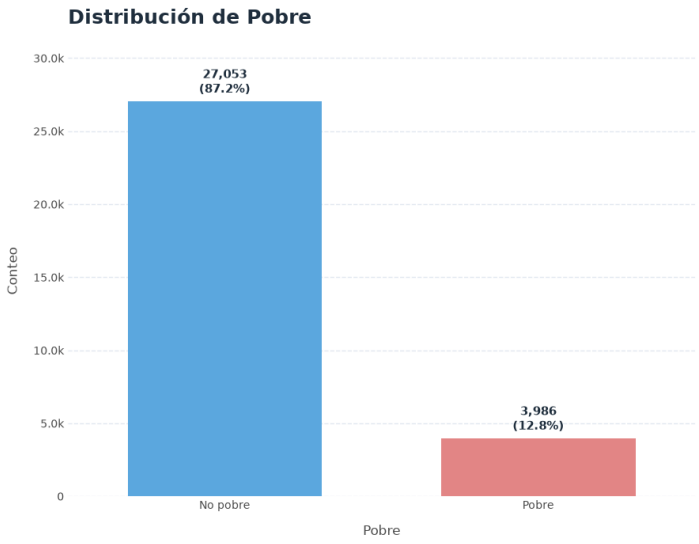


Figura 3. Distribución de la variable objetivo `POBRE` en el conjunto de entrenamiento. El 87,2 % de los hogares se clasifica como no pobre y el 12,8 % como pobre.

2.1.2. Segunda pipeline: Modelo ganador

La segunda propuesta conserva la imputación de valores faltantes, los indicadores de ausencia y la ponderación de clases de la primera pipeline, pero introduce dos cambios metodológicos principales. Primero, utiliza selección secuencial *forward* para elegir seis características según su *average precision*. Segundo, incorpora `MinMaxScaler` dentro del flujo de modelamiento, tanto durante la selección de características como antes del ajuste final de la regresión logística.

El escalado transforma las variables seleccionadas a un rango común, lo que facilita el tratamiento de características con escalas diferentes. La selección de variables y el escalado se integran en el procedimiento de validación cruzada para evitar que sus parámetros se estimen utilizando los pliegues de evaluación.

Esta propuesta resultó ganadora en la comparación inicial. Dado que las variantes logísticas mostraron desempeños relativamente similares, la decisión también consideró la estabilidad de las características seleccionadas y de sus coeficientes, así como la simplicidad del procedimiento.

2.2. Evaluación mediante validación cruzada

Para evaluar las pipelines se implementó la clase `EvaluadorCV`[1], que automatiza una validación cruzada estratificada y agrupada de cinco particiones. Esta clase resume las métricas de clasificación, registra la frecuencia de selección de variables y genera gráficos de precisión-recall, análisis del umbral y matriz de confusión. Las visualizaciones fueron desarrolladas con asistencia de Claude. Adicionalmente, las métricas se calculan a partir de las predicciones generadas por el código.

[La curva ROC no se implementó en esta ocasión debido al desbalance de las clases.]

2.3. Prevención de fuga de información

La prevención de fuga de información (*data leakage*) exige que las transformaciones que aprenden parámetros, como la imputación y la selección de características, se ajusten exclusivamente con los datos de entrenamiento de cada pliegue, y que luego se apliquen al pliegue de evaluación. Asimismo, el tratamiento del desbalance mediante `class_weight='balanced'` debe utilizar únicamente la distribución de clases del entrenamiento.

En este proyecto, el principal riesgo de circularidad surge de construir `POBRE` mediante el método de doble corte de Alkire-Foster. Por ello, los indicadores que participan

[1] Para más detalles consulte `utils/evaluador_cv.py`.

directamente en el cálculo de la etiqueta no deben incorporarse como predictores, pues permitirían reconstruir la regla de clasificación en lugar de aprender relaciones independientes. La prevención efectiva de esta fuga depende de que la selección de variables y las transformaciones se ejecuten dentro de cada partición, sin utilizar información del conjunto evaluado.

3. Entrenamiento y comparación de modelos

3.1. Modelo de línea base

Se utilizó un clasificador `DummyClassifier` que predice siempre la clase mayoritaria, correspondiente a los hogares no pobres. La línea base alcanza una exactitud cercana al 87,2 %, pero presenta sensibilidad nula, Kappa igual a cero y un *average precision* de aproximadamente 0,128.

Aunque su exactitud es elevada, el modelo no identifica hogares pobres. Por tanto, constituye una referencia útil para mostrar que acertar en la mayoría de los casos no garantiza un desempeño adecuado en la identificación de la clase minoritaria.

3.2. Modelos evaluados

La regresión logística es el modelo principal del proyecto, en correspondencia con el enfoque del artículo de referencia. Se compararon distintas variantes: ponderación de clases, ponderación con escalado MinMax, sobremuestreo SMOTE, sobremuestreo ADASYN, submuestreo y regularización Lasso. También se evaluaron Bernoulli Naive Bayes y KNN con submuestreo como alternativas.

La comparación considera el desempeño predictivo y la estabilidad de las características seleccionadas y de sus coeficientes entre pliegues. De este modo, la elección no depende exclusivamente de una única métrica, sino también de la consistencia y simplicidad del procedimiento.

3.3. Ajuste y comparación inicial

La Figura 4 presenta las estimaciones de las métricas y sus intervalos de confianza del 95 %, obtenidos mediante bootstrap con umbral de decisión de 0,5. La línea base muestra una exactitud elevada, pero no identifica la clase positiva. KNN obtiene la mayor precisión entre los modelos comparados, aunque su sensibilidad es menor que la de las variantes logísticas y Bernoulli Naive Bayes.

Las diferentes regresiones logísticas presentan resultados cercanos en exactitud, precisión, sensibilidad, Kappa y *average precision*. Las pequeñas diferencias observadas deben interpretarse considerando sus intervalos, pues no necesariamente representan mejoras reales entre modelos.

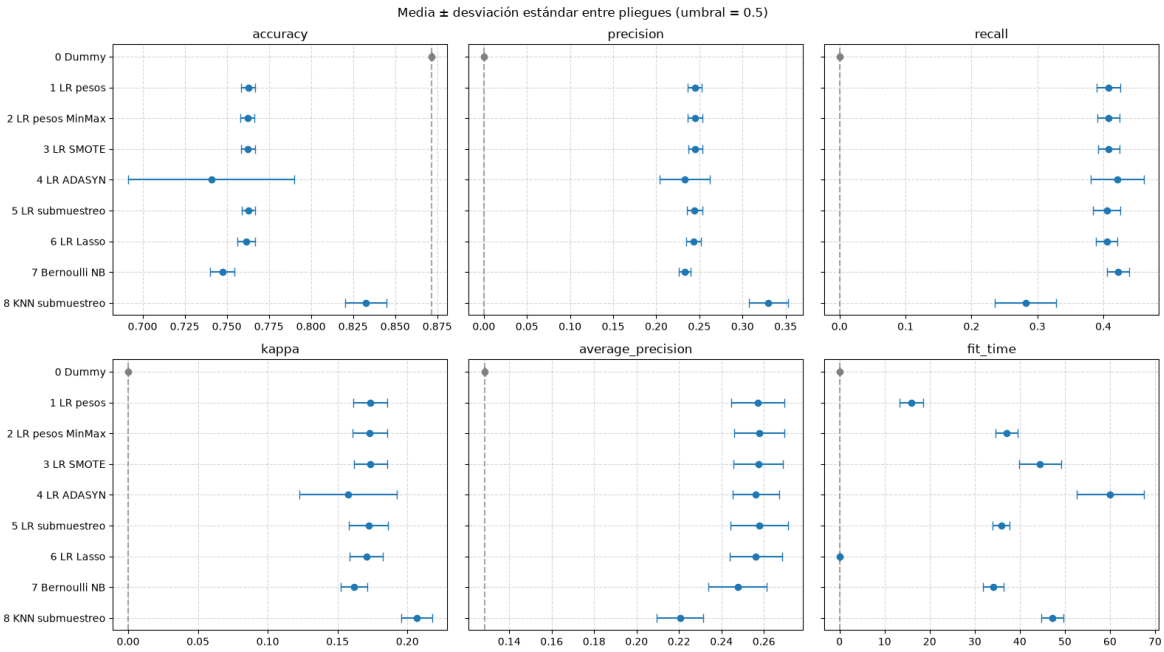


Figura 4. Estimaciones de desempeño e intervalos de confianza del 95 % mediante bootstrap de segmentos, con umbral de clasificación de 0,5.

La Figura 5 compara los AOR en escala de desviaciónes estándar para las distintas variantes logísticas. En general, los perfiles de los coeficientes son similares. Las barras representan los valores mínimo y máximo observados entre los cinco pliegues, no intervalos de confianza. Esta comparación permite examinar la estabilidad de las asociaciones estimadas entre las características y la clasificación de pobreza.

3.4. Selección del modelo ganador

Se seleccionó la propuesta 2, correspondiente a la regresión logística con ponderación de clases y escalado MinMax. Las variantes logísticas presentan métricas muy similares, por lo que las diferencias puntuales no bastan para establecer una superioridad concluyente. La decisión se fundamenta en la estabilidad de las características seleccionadas y de sus coeficientes, junto con la simplicidad metodológica del pipeline.

ADASYN no fue seleccionado porque sus cambios en las métricas no representan una mejora global suficiente frente a las otras variantes. SMOTE y el submuestreo producen resultados cercanos a los de la regresión logística ponderada, sin ofrecer una ventaja suficiente que justifique preferirlos. Lasso también presenta un desempeño comparable,

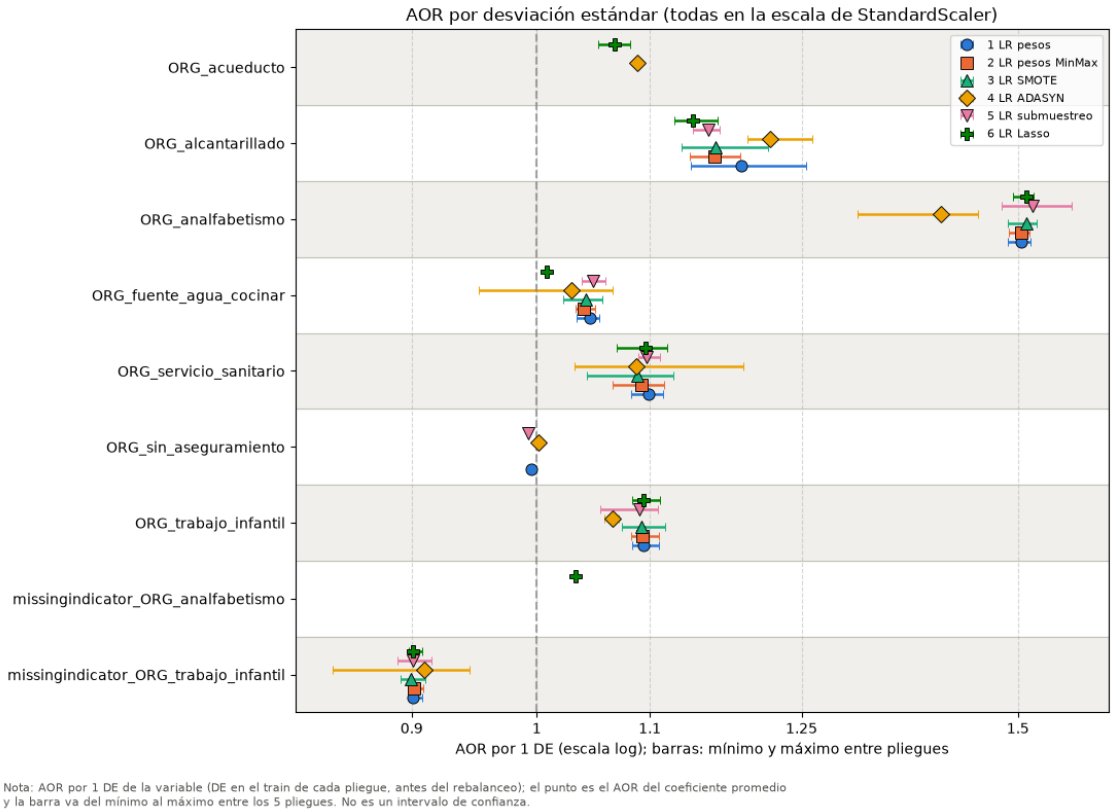


Figura 5. Razones de momios ajustadas por desviación estándar para las variantes de regresión logística. Las barras indican el rango entre pliegues.

pero no desplaza la elección realizada según los criterios conjuntos de estabilidad y simplicidad.

Bernoulli Naive Bayes obtiene una sensibilidad ligeramente superior a algunas variantes logísticas, pero presenta menor *average precision* y precisión, además de ofrecer menos interpretabilidad directa de las asociaciones mediante coeficientes. KNN logra la mayor precisión, pero su recall (metrica critica) es considerablemente menor y su área promedio bajo la curva precisión-recall es inferior. Por ello, no resulta la alternativa preferida cuando el objetivo es priorizar la detección de hogares pobres.

En síntesis, la propuesta 2 se selecciona como modelo ganador de esta iteración. La elección no implica que supere a todos los modelos en cada métrica, sino que ofrece el equilibrio más conveniente según los criterios de desempeño, estabilidad y simplicidad definidos para esta etapa.

4. Validación, métricas e interpretación preliminar

4.1. Estrategia de evaluación

En esta iteración se examina el desempeño mediante validación cruzada, utilizando diferentes métricas que muestran cómo varía el desempeño según los cambios en el umbral seleccionado; en específico, se utiliza StratifiedGroupKFold para tener en consideración los grupos que surgen del método de muestreo del DANE y el desbalance de clases. Siempre se reporta algo relacionado a bootstrap, el cual es un enfoque alternativo que no requiere reentrenamiento para ser ejecutado (pues era muy costoso computacionalmente con las pipelines implementadas). En específico, el enfoque trabaja de manera que crea un vector de predicciones global y hace el bootstrap sobre esos vectores; luego, en cada iteración saca valores de ese vector tomando en cuenta los grupos y, con base en los vectores extraídos, se calculan métricas. De ese proceso nacen las distribuciones empíricas que dan pie a los IC.

La evaluación definitiva sobre conjuntos de validación y prueba, así como la incorporación de otros algoritmos, entre ellos LDA y QDA, y procedimientos de ajuste como `GridSearchCV`, se reserva para la siguiente fase del proyecto.

4.2. Métricas de evaluación

Se consideran la exactitud (*accuracy*), la precisión (*precision*), la sensibilidad (*recall*), el coeficiente Kappa de Cohen y el área promedio bajo la curva precisión-recall (*average precision*).

La exactitud mide la proporción total de clasificaciones correctas. La precisión indica qué proporción de los hogares predichos como pobres realmente pertenece a esa clase, mientras que la sensibilidad mide qué proporción de los hogares pobres logra identificar el modelo. El Kappa mide la concordancia entre predicciones y clases observadas descontando la concordancia esperada por azar. El *average precision* resume el comportamiento de precisión y sensibilidad a distintos umbrales de decisión.

Dado el desbalance entre hogares pobres y no pobres, se evita seleccionar el modelo únicamente por exactitud. Se prioriza un análisis conjunto de las métricas, considerando especialmente la capacidad para detectar hogares pobres.

4.3. Resultados e interpretación

La línea base evidencia que una exactitud elevada puede coexistir con una sensibilidad nula. Por su parte, KNN favorece la precisión, pero deja sin identificar una proporción

importante de hogares pobres. Bernoulli Naive Bayes mejora ligeramente la sensibilidad frente a algunas variantes logísticas, aunque no presenta una ventaja global suficiente según los criterios considerados.

La regresión logística con ponderación de clases y escalado MinMax se mantiene como la alternativa seleccionada. Sus métricas son similares a las de las demás variantes logísticas y el análisis de los AOR muestra perfiles de coeficientes generalmente próximos. Por ello, la estabilidad entre pliegues y la simplicidad del pipeline resultan criterios relevantes para justificar la elección. Adicionalmente se agrega una interpretación de sus metricas (con un umbral de 0.48) y coeficientes.

Las metricas clave son el recall y la precision, pues permiten observar el trade off que hay entre ellos, en especifico para este modelo ganador se tiene un recall de 0.41 moderado a bajo con una precision baja de 0.238, suponiendo asi un modelo cuyo performance no es especialmente alto. Y que tiende a dar una alta cantidad de falsos positivos.

La interpretacion de los coeficientes se adjunta en la siguiente tabla

Tabla 2. Interpretación de los AOR del modelo de pobreza

Variable	**AOR**	**Interpretación**
`ORG_ analfabetismo`	14.5	Es el AOR más alto, lo que sugiere que es la característica más determinante. Un aumento de una unidad supondría que los odds son 14.5 veces más grandes, pero esto implicaría pasar de ningún analfabeta en el hogar a que todos lo sean; por lo tanto, es más fácil interpretarlo como un cambio de 0.1. Así, un aumento de 10 puntos porcentuales en la proporción de personas de 15 años o más analfabetas del hogar incrementaría los odds de pobreza en un 30,7 %; es decir, por cada 10 % más de personas analfabetas en el hogar, los odds de ser pobre se multiplican por 1.307.

Continúa en la siguiente página

Continuación de la tabla 2

Variable	AOR	Interpretación
ORG_trabajo_infantil	2.73	Es la proporción de personas de 12 a 17 años del hogar que trabajan. Pasar de ningún menor trabajando a que todos trabajen multiplicaría los odds por 2.73; nuevamente es un cambio extremo, por lo que se interpreta como un cambio de 0.1: por cada 10 puntos porcentuales más de menores de 12 a 17 años que trabajan, los odds de pobreza aumentan en un 10,6 % (se multiplican por 1.106). Nótese que en hogares con pocos menores el cambio es más brusco; por ejemplo, si el hogar tiene un solo menor y este empieza a trabajar, la proporción pasa de 0 a 1 y aplica el AOR completo.
ORG_alcantarillado	1.514	Es una variable binaria (1 = tiene alcantarillado, 2 = no tiene), por lo que un cambio de 0.1 no tiene sentido y se usa el AOR completo: un hogar sin alcantarillado tiene unos odds de pobreza 51,4 % más altos que uno con alcantarillado; es decir, sus odds se multiplican por 1.514.
ORG_servicio_sanitario	1.770	Es ordinal de 1 (inodoro conectado al alcantarillado) a 6 (sin servicio sanitario). Como MinMax lleva ese rango de 5 categorías a 1, un cambio de 0.1 equivale a media categoría y supone un aumento de 5,9 % en los odds de pobreza; por ello es más natural leerlo por una categoría completa: $1{,}770^{1/5} \approx 1{,}121$, es decir, cada categoría peor de servicio sanitario aumenta los odds de pobreza en un 12,1 %, y pasar del mejor al peor servicio los multiplica por 1.77.
ORG_fuente_agua_cocinar	1.229	Es ordinal de 1 (acueducto público) a 10 (agua embotellada o en bolsa), con un rango de 9 categorías; por lo tanto, un cambio de 0.1 equivale a casi una categoría (0.9) y supone un aumento de 2,1 % en los odds de pobreza. Por una categoría completa es $1{,}229^{1/9} \approx 1{,}023$, es decir, cada categoría peor de fuente de agua aumenta los odds de pobreza en un 2,3 %, y pasar de la mejor a la peor los multiplica por 1.229. Es la variable con menor efecto del modelo (también al expresarla por una desviación estándar).

Continúa en la siguiente página

Continuación de la tabla 2

Variable	AOR	Interpretación
`missingindicator_ ORG_trabajo_ infantil`	0.775	Vale 1 cuando el hogar no tiene personas de 12 a 17 años. También es binaria, por lo que se usa el AOR completo: los hogares sin menores de esa edad tienen unos odds de pobreza 22,5 % más bajos (se multiplican por 0.775) que los hogares con menores en los que ninguno trabaja.

Nota: Todas las interpretaciones se hacen considerando las demás variables constantes (controlando por).

La selección se considera preliminar: los resultados permiten comparar los procedimientos y documentar sus limitaciones, pero no sustituyen una evaluación final sobre datos independientes. En la siguiente fase se podrá comprobar la generalización del modelo seleccionado, explorar otros algoritmos y ajustar sus hiperparámetros.

Agradecimientos

Se reconoce el uso de herramientas de inteligencia artificial generativa, particularmente Claude, de Anthropic, y ChatGPT, de OpenAI, como apoyo en la comprensión de conceptos metodológicos, la organización de ideas, la revisión de la redacción académica y la asistencia en tareas de programación. Estas herramientas se utilizaron como recursos complementarios y no sustituyen el análisis crítico ni las decisiones metodológicas de los autores. Los autores son responsables de verificar la información, validar los procedimientos y resultados presentados, y garantizar la integridad académica del trabajo.

Referencias

Alkire, S. and Foster, J. (2011). Counting and multidimensional poverty measurement. *Journal of Public Economics*, 95(7–8):476–487.

Departamento Administrativo Nacional de Estadística (DANE) (2022). Metodología del Índice de pobreza multidimensional. https://www.dane.gov.co/files/operaciones/PM/met-IPM.pdf. Documento metodológico.

Departamento Administrativo Nacional de Estadística (DANE) (2025a). Encuesta nacional de calidad de vida (ecv) 2025. https://microdatos.dane.gov.co/index.php/catalog/905/study-description. Documentación y metadatos de la operación estadística.

Departamento Administrativo Nacional de Estadística (DANE) (2025b). Materiales relacionados con la encuesta nacional de calidad de vida. https://microdatos.dane.gov.co/index.php/catalog/905/related-materials. Documentación metodológica y materiales de consulta.

Departamento Administrativo Nacional de Estadística (DANE) (2025c). Índice de pobreza multidimensional (ipm). https://microdatos.dane.gov.co/index.php/catalog/903/study-description. Catálogo de información estadística.

Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature*, 585:357–362.

Hunter, J. D. (2007). Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95.

Lemaître, G., Nogueira, F., and Aridas, C. K. (2017). Imbalanced-learn: A python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research*, 18(17):1–5.

McKinney, W. (2010). Data structures for statistical computing in python. In *Proceedings of the 9th Python in Science Conference*, pages 56–61.

Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12(85):2825–2830.

Python Software Foundation (2025). Python documentation. https://docs.python.org/3/. Documentación oficial de Python.

scikit-learn developers (2025a). Cross-validation: Evaluating estimator performance. https://scikit-learn.org/stable/modules/cross_validation.html. Documentación oficial de scikit-learn.

scikit-learn developers (2025b). Pipeline. https://scikit-learn.org/stable/mo

dules/generated/sklearn.pipeline.Pipeline.html. Documentación oficial de scikit-learn.

Seabold, S. and Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with python.

Streamlit (2025). Streamlit documentation. https://docs.streamlit.io/. Documentación oficial de Streamlit.

Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in python. *Nature Methods*, 17:261–272.

Waskom, M. L. (2021). Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60):3021.

Zhao, e. a. (2024). Machine learning approaches for poverty prediction and identification. *PLOS ONE*.